

M2 AMI2B Biologie Computationnelle
Analyse, Modélisation et Ingénierie de l'Information Biologique et Médicale

Projet Programmation WEB

Bryan Brancotte

Conception d'une application web pour aider à l'assemblage de plasmides en utilisant des techniques de MoClo et de Golden Gate Assembly.

Contexte :

Une équipe de recherche fait en routine des assemblages de plasmides en utilisant des techniques de MoClo et de Golden Gate Assembly. Un plasmid de sortie est produit à partir de plusieurs plasmides d'entrée qui vont être découpés par des enzymes, puis réassemblés en le plasmid attendu. Le fait de réaliser l'assemblage de plusieurs plasmides au sein d'une même expérience est appelé campagne. Pour préparer une campagne, un biologiste va mettre dans un template (i.e. : fichier tabulé) sur une même ligne le nom du plasmide à produire, puis les plasmides à utiliser en entrée. Les plasmides utilisés en entrée ont un identifiant (pYTK045), mais afin de les rendre plus compréhensibles, il leur a été attribué un nom (Venus). Les biologistes utilisent soit les identifiants, soit les noms pour indiquer les plasmides utilisés en entrée.

La réalisation d'une campagne passe alors par la dilution des plasmides d'entrée afin d'obtenir un mélange équimolaire. Les plasmides, les enzymes, les sels et l'eau sont ensuite mélangés afin de permettre le découpage et l'assemblage du plasmid de sortie.

Une fois le/les plasmides produits, la qualité est évaluée par deux moyens, soit par digestion enzymatique, soit par amplification par PCR. Les deux techniques aboutissent à un ou plusieurs fragments du plasmid de sortie qui ont une taille prédictible. La taille des fragments est évaluée en utilisant l'électrophorèse sur gel d'agarose (Fig. 1).




Figure 1: Exemple d'électrophorèse ([src](#))

Afin de s'aider dans la planification et la réalisation des campagnes, l'équipe a conçu un outil en ligne de commande nommé InSillyClo. Il permet de générer des templates de campagne vides. Une fois un template rempli, l'outil permet de trouver les plasmides à utiliser, de calculer les dilutions à réaliser, et de simuler les gels de contrôle attendus selon les amorces PCR ou les enzymes de digestion utilisées (Fig. 2). En plus du template, l'outil prend en entrée un dossier contenant l'ensemble des séquences de plasmides au format GenBank, ainsi que des fichiers CSV de correspondance entre l'identifiant et le nom des plasmides.




Figure 2: Représentation schématique

Typage de données

Un typage est utilisé afin de gérer les plasmides, mais aussi de définir les assemblages à réaliser dans les templates de campagne. Les fichiers de correspondance peuvent avoir une troisième colonne indiquant le type du plasmide. Les templates présentent pour chaque colonne de plasmide en entrée, son/ses types ; pour chaque ligne, on indique le nom du plasmide à produire ainsi que le type que l'on obtiendra.

Sous-Typage de données

Le fichier Campaign_display_L1.xlsx donne un exemple de cette notion.

Lorsque les plasmides sont typés, on peut définir dans le template un type (par exemple « 3 »), mais aussi indiquer que le type est « [3a, 3b] », le plasmid sera alors faite plusieurs plasmides (deux dans ce cas) concaténé par un caractère défini aussi dans le template (ici « . »). En indiquant alors qu'on veut le plasmide « SPost1p.BGL » doit alors se lire comme demandant le plasmide « SPost1p » de type « 3a » suivit du plasmid « BGL » de type « 3b ». L'interprétation du template afin de trouver les séquences relève de l'outil en ligne de commande.

Données disponibles

Vous disposez sur eCampus dans d'une archive (data_web.zip) contenant :

- Des dossiers avec des plasmides. Un fichier pYTK045.gb est alors le fichier au format GenBank du plasmide identifié par pYTK045, et ce, même si le nom/identifiant spécifié dans le fichier peut différer.
- Deux dossiers avec des templates remplis typé ou non typé
- Des fichiers de correspondance typés et non-typés.

- Des fichiers commands.* exemplifiant l'utilisation de l'outil en cli, ou depuis du python
- Un fichier contenant des concentrations de certains plasmides.

Utilisateur/Utilisatrice

Par convention, on utilisera le masculin (utilisateur) pour caractériser les personnes ayant un rôle de base (connectées ou non), et le féminin pour les cheffes d'équipe et administratrices.

Initialisation : Chargement des données

Le template typé *Campaign_display_L1.xlsx* sera un template public, les séquences des dossiers pYTK et pYS seront deux collections publiques. Ces données seront à charger et à rendre disponibles dans l'application. Elles pourront être associées à une administratrice.

Les fonctionnalités principales attendues sont les suivantes.

Création de template de campagnes

Un utilisateur connecté pourra créer dans l'application un template de campagne. Cette création se fera pas un ou plusieurs formulaires. Il doit pouvoir modifier le template par la suite. Il peut le télécharger pour le remplir, puis simuler la campagne (cf. simulation de campagne).

En option (avancé) : On pourra télécharger le template (xlsx), le modifier (ajouter/retrait de colonne de plasmid) puis mettre à jour la modélisation en base de donnée du template à partir du template xlsx.

Téléchargement de template de campagnes

Un utilisateur non connecté pourra télécharger un template public pour le remplir et ensuite simuler la campagne (cf simulation de campagne).

Simulation d'une campagne

Un utilisateur non connecté pourra simuler une campagne. Pour ce faire, il devra à minima fournir le template de campagne correctement rempli, une archive contenant au moins toutes les séquences des plasmides qui seront utilisés en entrée, et une ou plusieurs correspondances permettant de couvrir la traduction du nom d'un plasmide vers son identifiant.

On nommera par la suite collection de plasmides les séquences des plasmides contenus dans l'archive.

De façon optionnelle, l'utilisateur peut fournir :

- les amorces PCR et/ou les enzymes en vue de la simulation des gels
- les concentrations de certains plasmides
- la concentration par défaut à considérer, et d'autres paramètres relatifs au calcul des dilutions.

Avantage à être un utilisateur connecté

Un utilisateur connecté pourra conserver ses collections de plasmides d'entrée et ses fichiers de correspondance. Il pourra sauvegarder une collection qu'il a fournie pour réaliser une simulation, alternativement il pourra aussi créer des collections *de novo*.

En option (avancé) : Les deux possibilité : sauvegarde, et de novo.

Au moment de lancer une simulation de campagne, un utilisateur pourra choisir d'utiliser une ou plusieurs de ses collections, des collections publiques et/ou fournir une archive avec d'autres séquences (i.e: une nouvelle collection). Un utilisateur pourra également utiliser les collections publiques de l'application. L'impact de la duplication des séquences entre plusieurs collections devra être étudié, l'utilisateur informé.

Un utilisateur connecté pourra conserver les correspondances entre l'identifiant d'un plasmide et son nom (et type, si défini). Les conflits de correspondance ne devront pas être négligés, tout en considérant qu'une même séquence de plasmide peut être présente dans plusieurs fichiers GenBank avec des identifiants différents.

Gestion des utilisateurs et des projets

L'accès à l'outil peut se faire sans authentification, mais certaines fonctionnalités ne sont alors pas utilisables. Chaque utilisateur connecté a un email qui l'identifie ainsi qu'un mot de passe sécurisé. Un utilisateur a un prénom et un nom. L'utilisateur peut avoir plusieurs rôles : utilisateur, cheffes d'équipe, administratrice. Un lecteur peut lire les informations de la base (poser ses requêtes grâce à un formulaire). Une cheffe d'équipe peut faire tout ce que fait un utilisateur. Elle peut gérer son équipe. Elle peut aussi ajouter, retirer ou modifier des collection de séquences et des tables de correspondance pour son équipe. Une administratrice peut rendre publiques des templates de campagne, des groupes de séquences et des tables de correspondance.

L'administratrice du système a accès à la liste des utilisateurs ; elle est la seule à pouvoir passer un utilisateur en administratrice. Elle peut voir la date (et l'heure) de la dernière connexion d'un utilisateur au système.

Chaque nouvel utilisateur devra remplir un formulaire avec ses informations (email, nom, prénom...). Pour simplifier l'outil et parce que c'est un projet, l'utilisateur peut choisir d'être utilisateur ou administratrice. Lorsqu'il a rempli tous les champs, il clique

sur un bouton (par exemple “créer l'utilisateur”), ce qui aura pour effet de créer l'utilisateur.

Gestion d'équipe

Tout utilisateur peut créer une équipe, cette personne devient alors cheffe d'équipe de cette équipe. On peut être cheffe de plusieurs équipes. On peut ajouter ou retirer des utilisateurs de notre équipe.

En option : *Les collections et tables de correspondance peuvent être attachées à l'équipe. Les membres peuvent alors les utiliser. Seul la cheffe d'équipe peut choisir d'attacher des collections ou table depuis les siennes ou celle des membres de l'équipe. Seul le propriétaire peut modifier une collection/un table.*

En option : *on pourra transférer la propriété d'une équipe à un membre de son équipe.*

Sélection des informations relatives à un plasmid

L'utilisateur du système peut accéder aux données du système en sélectionnant les informations par le biais d'un formulaire. On considère ici un unique formulaire qui contiendra en attributs tous les champs d'intérêt présents dans l'ensemble des types de fichiers GenBank. Si l'utilisateur remplit plusieurs champs, il conviendra de les combiner par un « ET ».

Un utilisateur peut rechercher des plasmides :

- contenant un motif de séquence (« %ATGC% »). On fixera une taille minimale de la sous-séquence nucléotidique ou peptidique à 3 résidus.
- par leur nom ou une sous chaîne.
- par un ou plusieurs types, ou absence de type
- par un ou plusieurs sites de fixation (BsaI, NotI , ...)

La liste des résultats est cliquable, lorsqu'on sélectionne un résultat on accède à sa vue détaillée.

En option : *l'autocomplétion pourra être proposée pour les noms de plasmides, les types ou encore les site de fixation et ceux en fonction des valeurs existantes dans la base. Elle pourra être écarté lorsqu'elle n'est pas pertinente.*

En option : *On pourra faire une recherche par similarité avec un motif, à vous de définir et proposer ce que pourrait être cette similarité.*

Visualisation des informations

Lorsque l'utilisateur clique sur un résultat de recherche de plasmides, il doit pouvoir visualiser le génome du plasmide, et notamment les annotations. **La visualisation est libre**, différentes stratégies pourront être explorées : utiliser des couleurs qui changent d'un gène à l'autre ou mettre certaines séquences en gras, en italique, etc. Une

fonctionnalité souhaitable est de permettre de rendre le génome cliquable : on voudrait pouvoir cliquer sur une annotation et afficher des informations complémentaires lorsque cela a du sens (par exemple, pour un site de fixation, on peut afficher des liens vers des sources de données externes).

Extraction des données déjà annotées

L'ensemble des données/collections présentes dans la base peuvent être extraites sous une forme proche de celle utilisée pour les fournir.

***En option :** On pourra extraire les séquences de plusieurs collections de plasmides, et ne choisir qu'un sous ensemble dans chaque collection.*

Accès aux informations complémentaires des banques de données

D'autres banques de données disponibles peuvent être interrogées. L'utilisateur doit pouvoir accéder à ces informations complémentaires sur demande : il accède à une liste de banques de données disponibles dans une liste déroulante et en choisit une. La sélection de la banque entraîne l'ouverture d'une nouvelle page web sur la banque choisie, interrogée grâce à l'attribut qui permet de faire le lien avec la banque (identifiant, séquence, mots-clés, nom du gène, nom du transcrit, etc.).

Il convient de déterminer la ou les bases de données pertinentes que vous êtes prêt à mettre en relation avec les données lors de votre livrable 1.

Ré-utilisation des nouveaux plasmides

Un plasmide produit par une simulation de campagne pourra être conservé et ajouté à ses collections de plasmides. En effet, on peut réaliser une première campagne produisant des plasmides et réutiliser ces derniers dans une seconde campagne afin d'obtenir de nouveaux plasmides. Les nouveaux plasmides conservent les annotations des fragments qui les constituent, l'utilisateur pourra cependant modifier les annotations.

Publication de plasmides

Un utilisateur peut demander qu'une collection de plasmides devienne publique ; une administratrice doit alors pouvoir visualiser rapidement l'ensemble des plasmides de la collection et accepter ou refuser la publication. En cas de refus, la décision devra être justifiée à destination de l'utilisateur.

Lorsqu'une administratrice se connecte au système, elle peut accéder à une interface dans laquelle l'ensemble des demandes de publication sont listées.

***En option :** un email est envoyé aux administratrices pour les informer qu'une nouvelle demande de publication vient d'être faite (cf `django.[...].console.EmailBackend`)*

En option : afin d'alléger la charge de travail des administratrices, une demande de publication doit d'abord être validée par la cheffe d'équipe. Ensuite seulement, la demande de validation est visible pour les administratrices.

Publication des tables de correspondance

Le besoin est le même que pour les plasmides.

Historique de l'outil sous-jacent

L'équipe derrière l'outil InSillyClo ([paper](#)) a déjà proposé une application web, mais celle-ci ne couvre pas l'ensemble des cas d'utilisation présentés ici. Dans un cas réel (stage, CDD/CDI), il serait demandé de partir de l'existant et de le faire évoluer. L'objectif de ce projet est de proposer une nouvelle application ; vous ne réutiliserez pas le code du premier site web, vous n'importerez pas les tutoriels. Les idées présentes dans le premier site web ne sont cependant pas à proscrire, vous pouvez les réutiliser et/ou adapter.

Gestion du code source

Utilisez git pour versionner vos source, github ou gitlab. Vous pouvez mettre votre projet en publique ou en privé. Dans les deux cas ajouter bryan-brancotte au projet avec le rôle Mainten(er) afin qu'il puisse voir vos sources et l'évolution de votre projet.

Les issues et/ou les projects pourront vous aider dans la gestion de votre projet, à vous de savoir si vous voulez vous en servir.

Dans le cas peu probable où une partie des membres du projet n'apparaîtrait pas ou peu dans les *contributors*, il conviendra alors de justifier de l'implication des membres en question par d'autre moyen.

Sécurité dans votre application

Une attention particulière sera portée sur la sécurité de votre application : est-ce que l'accès aux vues est bien contrôlé, est-ce que les entrées utilisateur sont bien filtrées pour ne pas avoir d'injection de code, est-ce qu'aucun vrai mots de passe n'est écrit en dur dans les sources, ...

2- Déroulement Projet, jalons et évaluation

Les séances de suivi se dérouleront selon le calendrier ci après. Chaque groupe à un créneaux fixe de 25 minutes durant lequel l'encadrant prend le rôle d'utilisateur, mais aussi de senior de l'équipe vous conseillant sur vos choix.

03 Décembre : Démarrage du projet . Formez des groupes de 4, des groupes de 3 sont possible. Choisissez GitHub ou GitLab, et créer le projet, et ajoutez y l'encadrant avec le rôle Mainten(er).

07 janvier : Suivi des projets et questions par groupes

10 janvier: rendu Livrable 1

Il sera envoyé par mail à bryan.brancotte@pasteur.fr avec comme sujet *[Projet-Web Jalon 1] noms*. Une archive zip sera jointe contenant les documents suivant

- Fichier Readme.md avec
 - noms/prénoms des membres du projet
 - url du git du projet
 - Ensemble de commande à exécuter pour que l'application se lance
- Répertoire source: ensemble des sources du projet.
- BD : Un schema de la base de donnée (django-extensions)
- Web : Le site contient une ébauche du thème graphique, les principales vues sont partiellement en place même si elles ne contiennent pas d'information, les boutons ne sont pas forcément tous fonctionnels mais permettent de se rendre compte de l'utilisation futur. Lorsque les vues sont manquantes, des maquettes donnent une idée de ce que vous envisagez.
- Fonctionnement : Une description du fonctionnement global de l'outil du point de vue de l'utilisateur (on débute sur <http://localhost:8000/> puis si on clique sur le bouton « recherche » la page... s'ouvre). Cette description peut prendre la forme de votre choix (document rédigé, slides explicites, schémas commentés...)
- Fonctionnalités : la liste des fonctionnalités que vous comptez faire (parmi les fonctionnalités optionnelles) et la liste des bases extérieures auxquelles vous proposerez l'accès doit être trouvable soit dans un fichier features.md, soit en créant des issues et discutant dans ces derniers des avancements des travaux. Cela peut être juste « Fait » ou « Abandonnée », ou contenir plus de détails avec les points bloquant et les solutions que vous apportez.

14 Janvier : Retour sur le rendu 1, suivi des projets.

21 janvier : Suivi des projets et questions par groupes.

28 janvier : Suivi des projets et questions par groupes.

04 février : Suivi des projets et questions par groupes.

10 février : rendu Livrable

Il sera envoyé par mail à bryan.brancotte@pasteur.fr avec comme sujet *[Projet-Web Final] noms*. Une archive zip sera jointe contenant les documents suivant

- Fichier Readme.md avec
 - noms/prénoms des membres du projet
 - url du git du projet
 - Ensemble de commande à exécuter pour que l'application se lance
- Répertoire source: ensemble des sources du projet.
- BD : Un schema de la base de donnée (django-extensions)
- Répertoire Doc : (1) documentation orientée utilisateur de l'outil (équivalent 3-5 pages), (2) documentation technique décrivant sur quelles installations l'outil repose (1/2 à 1 page) et (3) retour d'expérience sur l'organisation du projet (1/2 à 1 page)

11 février: Soutenance du projet

Critères d'évaluation

1) Documentation : 20%

2) Présentation orale (10 min + 5 min questions) : 30%

3) Qualité des sources, gestion d'équipe et de projet : 50% - Attention : avant de considérer des fonctionnalités optionnelles vous devez vous assurer que les fonctionnalités attendues sont opérationnelles et de bonne qualité.

Contenu de la soutenance :

Votre soutenance présentera l'application que vous avez conçu, et montrera son utilisabilités. Elle présentera les rôles de chaque chacun·ne.

Horaires et groupes constitués

9h30 – 9h55 Groupe 1

10h00 – 10h25 Groupe 2

10h30 – 10h55 Groupe 3

11h00 – 11h25 Groupe 4

11h30 – 11h55 Groupe 5

12h00 – 12h30 Groupe 6

Groupe 1 :

Groupe 2 :

Groupe 3 :

Groupe 4 :

Groupe 5 :

Groupe 6 :